



Proyecto de Grado

**BrainCEMISID: Una Arquitectura Cognitiva Sintética utilizando Inteligencia
Artificial Generativa**

Por

Br. Johan Manuel Paredes Pino

Tutor: Prof. Dr. Junior Altamiranda

Septiembre, 2026

©2026 Universidad de Los Andes, Mérida, Venezuela

Agradecimientos

A mi tutor, Prof. Dr. Junior Altamiranda, por su invaluable guía, paciencia y rigor académico, que han sido determinantes para el éxito de esta investigación. A la Universidad de Los Andes, mi casa de estudios, por brindarme el espacio y las herramientas necesarias para mi desarrollo profesional. A la Cantoría de Mérida, mis amigos más cercanos, y a su director, el Prof. Geraldo Arrieche, por todas sus enseñanzas.

Resumen

Abstract

Esta investigación presenta BrainCEMISID, una arquitectura cognitiva sintética diseñada para superar las limitaciones de los modelos de lenguaje (LLMs) actuales en términos de razonamiento a largo plazo, memoria persistente y coherencia emocional. Basada en un enfoque neuro-simbólico y modular, la arquitectura integra un orquestador central con módulos especializados en percepción sensorial, planificación deliberativa, memoria vectorial y regulación emocional. La evaluación, realizada mediante simulaciones de escenarios de estrés cognitivo y un marco de juicio sintético (LLM-as-a-judge), demuestra que BrainCEMISID mejora significativamente el rendimiento en comparación con los LLMs estándar, alcanzando una mayor consistencia de personalidad ($d=1.55$) y coherencia lógica. Los resultados validan que la orquestación explícita de componentes cognitivos puede ayudar a transformar a los LLMs de generadores estocásticos (Sistema 1) en agentes deliberativos (Sistema 2), sentando las bases para el desarrollo de Inteligencia Artificial General (IAG) más robusta y confiable.

Tabla de Contenido

Capítulo I. Introducción	5
Capítulo II. Marco Teórico	11
Capítulo III. Marco Metodológico	15
Capítulo IV. Análisis y Discusión de Resultados	30
Capítulo V. Conclusiones y Trabajo Futuro	36
Referencias	41
Anexos	43

Índice de Figuras

Figura 1. Arquitectura principal del BrainCEMISID	17
Figura 2. Diagrama de Actividades del proceso de generación de respuesta	19
Figura 3. Flujo de Evaluación	26
Figura 4. Comparación de Rendimiento BrainCEMISID vs Baseline	31
Figura 5. Comparación BrainCEMISID vs Baseline (Gráfico de radar)	32
Figura 6. Comparación de rendimiento incluyendo análisis de ablación	34
Figura 7. Comparación de Latencia BrainCEMISID vs Baseline	35

Índice de Tablas

Tabla 1. Tabla de Rendimiento	30
-------------------------------------	----

Capítulo I. Introducción

1.1. Planteamiento del problema

La Inteligencia Artificial (IA) ha experimentado una transformación radical con el surgimiento de los Large Language Models (LLMs), los cuales han demostrado capacidades sin precedentes en la comprensión y generación de lenguaje natural, y en tareas de razonamiento de corto alcance. Sin embargo, a pesar de su impresionante habilidad para imitar la conversación y la generación de contenido, los LLMs actuales operan principalmente dentro de una ventana de contexto limitada y exhiben deficiencias significativas en la replicación de un razonamiento cognitivo completo y coherente.

Estos modelos a menudo luchan con:

- **Planificación a Largo Plazo:** Su naturaleza secuencial y la falta de un modelo del mundo persistente impiden una planificación estratégica efectiva a través de múltiples pasos distantes.
- **Memoria Persistente y Selectiva:** Carecen de mecanismos robustos para almacenar y recuperar información crucial más allá de su prompt inicial o ventana de contexto, lo que resulta en la repetición de errores o la "pérdida de foco" en tareas prolongadas.
- **Fiabilidad y Coherencia:** La naturaleza estocástica del LLM los hace propensos a la "alucinación", generando información falsa o inconsistente, lo cual compromete la confiabilidad en aplicaciones críticas.

Estos desafíos señalan una brecha crucial: mientras que los LLMs son un motor de inferencia lingüística potente, no constituyen, por sí mismos, una Arquitectura Cognitiva

completa. Para avanzar hacia agentes de IA que puedan interactuar con el mundo de manera robusta, tomar decisiones complejas y aprender de la experiencia, es fundamental integrar el poder del LLM con una arquitectura cognitiva.

1.2. Delimitación del problema

El problema a abordar es la falta de una arquitectura cognitiva que integre de manera cohesiva y recursiva la percepción multisensorial, la emoción, la memoria y la modulación del comportamiento para generar una corriente de conciencia artificial con una evolución plausible de la personalidad. La mayoría de las arquitecturas actuales son incapaces de simular la deriva conductual o los cambios graduales y no aleatorios en las tendencias de comportamiento y los rasgos de personalidad en respuesta a experiencias acumuladas. Esta investigación se centra en el diseño e implementación de una arquitectura que supere estas limitaciones. El trabajo se limita a una simulación computacional de la arquitectura BrainCEMISID y sus componentes, y su evaluación a través de métricas de recuperación de recuerdos, consistencia emocional y realismo.

1.3. Objetivos

1.3.1. Objetivo general

Diseñar e implementar una Arquitectura Cognitiva basada en un LLM con módulos de memoria y planificación y evaluar su impacto en la efectividad de planificación y la coherencia de razonamiento en un entorno de simulación de toma de decisiones.

1.3.2. Objetivos específicos

- **Revisar** los modelos teóricos de Arquitecturas Cognitivas e identificar los componentes clave de memoria y planificación aplicables a LLMs.
- **Desarrollar** y parametrizar la Arquitectura Cognitiva (módulos de memoria, planificación e integración con el LLM).
- **Comparar** el rendimiento del agente basado en la nueva arquitectura contra un LLM de baseline en métricas de planificación y coherencia dentro del entorno de simulación.

1.4. Metodología

La investigación se basa en un enfoque de diseño y validación de una arquitectura cognitiva sintética. El diseño de BrainCEMISID sigue un enfoque modular, con componentes interconectados cuya implementación de los módulos principales se realiza en Python. La metodología de evaluación incluye la realización de simulaciones en entornos sintéticos y con conjuntos de datos multisensoriales del mundo real. El benchmarking se llevará a cabo en bancos de pruebas de arquitecturas cognitivas estándar, y el rendimiento se medirá a través de indicadores como la retención de contexto, la latencia de cambio de atención, la consistencia emocional y la puntuación de deriva conductual.

1.5. Justificación

La investigación aporta conocimiento nuevo al formalizar un modelo híbrido que integra la Arquitectura Cognitiva clásica con las capacidades generativas de los Large Language Models (LLMs). Teóricamente, el estudio aborda la disyuntiva actual en la IA: cómo combinar la

representation del conocimiento simbólico (esencial para la planificación explícita y la memoria estructurada) con los patrones de razonamiento inductivo y emergente de los LLMs. Al diseñar y validar un marco que fusiona estos paradigmas, esta tesis contribuye directamente a la comprensión de cómo los agentes de IA pueden trascender la "ventana de contexto" y el razonamiento a corto plazo, sentando las bases conceptuales para el desarrollo de una Inteligencia Artificial General (IAG) más robusta y coherente.

1.6. Antecedentes

El desarrollo de una arquitectura cognitiva sintética como BrainCEMISID se enmarca en la confluencia histórica de dos campos fundamentales de la Inteligencia Artificial (IA): las Arquitecturas Cognitivas (ACs) clásicas y los recientes avances en la Inteligencia Artificial Generativa.

1.6.1. La Relación Mutua entre Arquitecturas Cognitivas y LLMs

Los antecedentes sugieren una relación sinérgica y bidireccional entre ambos enfoques. Sun (2024) [1] explora si una Arquitectura Cognitiva (AC) puede fundamentalmente mejorar a los LLMs, y viceversa. Este trabajo argumenta que la incorporación de la psicología y la cognición humana, encarnada en una AC computacional, es esencial para desarrollar sistemas de IA que sean más capaces, fiables y humanoides. Sun destaca la importancia de una arquitectura de doble proceso (simbolismo explícito vs. intuición implícita) y el enfoque híbrido neuro-simbólico como vía para mitigar las deficiencias de los LLMs actuales [1].

En línea con esta visión, Romero et al. (2023) [4] realizan un análisis exploratorio de la integración sinérgica, identificando tres enfoques clave para esta hibridación:

1. **Enfoque Modular:** Introduce modelos con grados variables de integración, donde el LLM interactúa con componentes externos (como memoria o planificación) que se inspiran en modelos como el Common Model of Cognition.
2. **Enfoque de Agencia:** Propone colecciones de agentes que interactúan a niveles micro y macro-cognitivos.
3. **Enfoque Neuro-Simbólico:** Propone que el aprendizaje bottom-up extraiga representaciones simbólicas de una capa del LLM, mientras que la guía top-down utiliza estas representaciones para dirigir la ingeniería de prompts en el LLM.

1.6.2. Marcos Estructurados y Componentes Clave

Para organizar la explosión de agentes de lenguaje impulsados por LLMs, Sumers et al. (2024) [2] proponen el marco Cognitive Architectures for Language Agents (CoALA). Este marco sistematiza a los agentes de IA basándose en tres dimensiones históricas de la ciencia cognitiva:

1. **Almacenamiento de Información:** Dividido en memoria de trabajo (corta duración) y memoria a largo plazo (episódica, semántica, procedimental).
2. **Espacio de Acción:** Distinguiendo entre acciones internas (razonamiento, recuperación de memoria) y acciones externas (interacción con el entorno).
3. **Procedimiento de Toma de Decisiones:** Estructurado en un bucle interactivo de planificación y ejecución.

El marco CoALA es fundamental, ya que contextualiza los agentes de lenguaje actuales dentro de la historia de la IA y proporciona una hoja de ruta para el desarrollo de una inteligencia general basada en el lenguaje, destacando que el proceso de toma de decisiones debe involucrar ciclos de planificación y ejecución.

1.6.3. Aplicaciones y la Arquitectura Híbrida

La necesidad de robustez y fiabilidad ha llevado a la aplicación de arquitecturas cognitivas en dominios críticos. Wu et al. (2024) [3] abordan la dicotomía entre el razonamiento ruidoso (propensos a alucinaciones) de los LLMs y los procesos restringidos de las AC para la toma de decisiones en la fabricación.

Ellos presentan LLM-ACTR, una arquitectura neuro-simbólica novedosa que integra la arquitectura cognitiva ACT-R (famosa por modelar mecanismos internos de la toma de decisiones humana) con los LLMs [3]. El método de Wu y colaboradores extrae conocimiento del proceso de decisión de ACT-R y lo inyecta como representaciones neuronales en capas adaptadoras del LLM, ajustando el modelo (fine-tuning) para predicciones posteriores. Sus resultados demuestran un rendimiento mejorado y una capacidad de decisión superior en comparación con los modelos base, basados únicamente en la estrategia Chain-of-Thought [3].

En resumen, los antecedentes confirman que la integración modular de componentes de planificación y memoria dentro de un marco cognitivo, tal como se propone en esta tesis, representa la dirección dominante para superar las limitaciones de los LLMs y avanzar hacia una IA más robusta y alineada con la cognición humana [1, 2, 4].

Capítulo II. Marco Teórico

Esta sección establece las definiciones y principios conceptuales que sostienen la arquitectura y metodología propuestas en la tesis.

2.1. Bases Teóricas

2.2.1. *Arquitecturas Cognitivas (AC)*

Las Arquitecturas Cognitivas son marcos de trabajo teóricos y computacionales que buscan modelar la estructura fija de la mente que subyace y da forma al comportamiento inteligente [5]. Las AC se centran en replicar la cognición de alto nivel y la coherencia a largo plazo, contrastando con los modelos de deep learning que se centran en tareas específicas. Son esenciales para el desarrollo de sistemas que exhiben razonamiento deliberado, un concepto central en la psicología cognitiva.

Se debe adoptar la visión modular de la AC para estructurar la interacción del LLM con sus componentes externos, asegurando que el agente no solo sea capaz de generar texto coherente, sino de ejecutar un plan de acción coherente basado en un modelo del mundo.

2.2.2. *Large Language Models (LLMs)*

Los modelos de lenguaje grandes (LLM), son sistemas de aprendizaje profundo diseñados para procesar el lenguaje. Se exponen a colecciones masivas de textos y su objetivo de entrenamiento explícito es predecir con éxito la siguiente palabra (o una palabra que falta) en una frase o párrafo [6]. Aunque inicialmente se diseñaron para tareas de lenguaje (traducción,

resumen), su escala ha permitido la emergencia de capacidades de razonamiento inductivo y conocimiento del mundo implícito.

Su principal fortaleza es su capacidad para el razonamiento intuitivo y la generalización lingüística. Sin embargo, su ventana de contexto finita y su naturaleza estocástica son las limitaciones que la Arquitectura Cognitiva busca corregir.

2.2.3 El Problema de la Alucinación, la Fundamentación (Grounding) y el Sesgo

La Alucinación se refiere a la generación de contenido factualmente incorrecto o no fundado por parte del LLM. El Grounding (Fundamentación) es la capacidad de un agente para vincular sus representaciones internas (el texto generado) con el conocimiento externo (memoria, entorno) de manera coherente [9].

Una limitación igualmente crítica es la transferencia de sesgos presentes en el gigantesco dataset de entrenamiento del LLM. Estos sesgos pueden manifestarse en decisiones sesgadas, representaciones injustas o la perpetuación de estereotipos [9].

Los LLMs son esencialmente cajas negras; su razonamiento es implícito y opaco, lo que dificulta la explicabilidad y la depuración cuando se produce un error de sesgo o incoherencia.

2.2.4. Inteligencia Artificial General (AGI)

El concepto de Inteligencia Artificial General (AGI) es el objetivo máximo de la investigación en IA. Se define como la inteligencia de una máquina que tiene la capacidad de entender, aprender y aplicar su conocimiento para resolver cualquier tarea intelectual que un ser humano pueda realizar. A diferencia de la Inteligencia Artificial Estrecha (IAE), que son

sistemas expertos en dominios limitados, la IAG exhibe flexibilidad, adaptabilidad y transferencia de conocimiento entre dominios [8].

2.2.5. Modelos Duales de Razonamiento (Sistema 1 vs. Sistema 2)

La psicología cognitiva moderna, popularizada por Kahneman [7], diferencia entre dos sistemas de pensamiento:

- **Sistema 1:** Es rápido, automático, frecuente, emocional, estereotipado y subconsciente; su función es generar intuiciones que con frecuencia nos sirven adecuadamente, pero no siempre.
- **Sistema 2:** Es lento, requiere esfuerzo, poco frecuente, lógico, calculador y consciente; su función es tomar las decisiones finales tras observar y controlar las intuiciones del Sistema 1.

Los LLMs puros son a menudo vistos como potentes sistemas 1, que sobresalen en la generación fluida, pero fallan en la deliberación y el control explícito. La Arquitectura Cognitiva que se propone actúa como el Sistema 2, proporcionando los mecanismos de control, planificación y memoria a largo plazo necesarios para corregir y guiar las intuiciones del LLM, incrementando la coherencia del razonamiento.

2.2.6. Evaluación de Agentes mediante LLM-as-a-Judge

El paradigma LLM-as-a-judge surge como una respuesta a las limitaciones de las métricas automáticas tradicionales y de los modelos pequeños, los cuales suelen fallar al evaluar tareas generativas en escenarios abiertos y dinámicos.

Este enfoque propone utilizar modelos de lenguaje de gran escala para calificar, clasificar o seleccionar respuestas generadas por otros modelos, permitiendo una evaluación mucho más cercana al juicio humano en dimensiones matizadas como la utilidad, la seguridad, la fiabilidad y la coherencia lógica [10]. Operativamente, puede implementarse mediante formatos puntuales, comparativos o jerárquicos. Además de su capacidad para escalar evaluaciones, este marco facilita el desarrollo de agentes inteligentes al permitir procesos de alineación, autorreflexión y toma de decisiones basados en retroalimentación sintética.

Capítulo III. Marco Metodológico

3.1. Tipo y Enfoque de la Investigación

La presente investigación adopta un enfoque de diseño y validación en el campo de la Inteligencia Artificial. Su objetivo principal es la creación, implementación y evaluación empírica de la arquitectura BrainCEMISID.

3.1.1. Enfoque Metodológico

El enfoque de la investigación es predominantemente cuantitativo. La validación de la arquitectura se fundamenta en la medición objetiva de variables de rendimiento y comportamiento, las cuales se identificarán mediante métricas de efectividad de planificación y coherencia de razonamiento.

3.1.2. Tipo de Diseño

Se emplea un diseño experimental comparativo. Este diseño requiere la implementación de un grupo de control (un LLM puro) y un grupo experimental (el Agente BrainCEMISID). El propósito es aislar y medir el impacto directo de la Arquitectura Cognitiva en las capacidades del agente, superando las deficiencias inherentes a la ventana de contexto limitada y la falta de coherencia a largo plazo del LLM.

3.2. Diseño de la Arquitectura BrainCEMISID

El diseño de la arquitectura sigue un enfoque modular y neuro-simbólico, donde un orquestador central coordina la interacción entre el Large Language Model (LLM) y cuatro módulos especializados.

3.2.1. Descripción de Módulos Funcionales

- **Orquestador Central:** Actúa como el puente de control y gestión de datos entre el modelo de lenguaje principal y los sistemas periféricos. Es el responsable de ejecutar el ciclo de procesamiento, garantizando que la salida final sea el resultado de una deliberación multi-modular.
- **Módulo Sensorial:** Este componente actúa como los "ojos y oídos" del agente. Su función principal es obligar al sistema a realizar una clasificación explícita de estímulos antes de procesar la narrativa. Este paso es crítico para mitigar las alucinaciones ambientales.
- **Módulo de Planeación:** Funciona como un mecanismo de deliberación interna que desglosa objetivos complejos en pasos atómicos. Al generar este "monólogo interior", el sistema puede identificar riesgos y evitar acciones contradictorias.
- **Módulo de Emociones:** Regula la valencia emocional del agente en respuesta a factores estresantes. Utiliza tasas de disminución matemática para normalizar estados fisiológicos simulados, permitiendo que el perfil emocional evolucione de manera orgánica.

- **Módulo de Memoria:** Gestiona la persistencia de datos a través de una base de datos vectorial. Permite recuperar contextos, nombres y reglas técnicas establecidos en etapas anteriores, mitigando la pérdida de foco derivada de la ventana de contexto finita.




Figura 1. Arquitectura principal del BrainCEMISID

3.3. Ciclo de Procesamiento

El funcionamiento operativo de BrainCEMISID se ejecuta de forma recursiva a través de un ciclo de seis etapas, como se ilustra en la Figura 2:

1. Extracción de estímulos y Fundamentación Sensorial: En esta fase inicial, el Módulo Sensorial actúa como un filtro de realidad. Identifica y clasifica sensaciones físicas, obligando a la arquitectura a situarse en su entorno antes de formular cualquier intención de respuesta.

2. Ajuste de Estado Emocional: El Módulo de Emociones calcula la valencia y la intensidad del estado interno. Utiliza tasas de disminución para modelar cómo estados como el pánico descienden gradualmente, asegurando que el agente no permanezca neutral ante eventos disruptivos.

3. Creación del Plan de Acción y Monólogo Interno: El Módulo de Planeación actúa como un monólogo interior, desglosando el objetivo en pasos intermedios. Esta deliberación integra el estado previo, evitando acciones contradictorias o imposibles.

4. Recuperación de Contexto Semántico (Memoria): El Módulo de Memoria realiza una consulta a la base de datos vectorial para recuperar datos clave. Este proceso permite a la arquitectura mantener la coherencia más allá de la ventana de contexto estándar.

5. Construcción del Prompt Unificado: El Orquestador centraliza las salidas en una única indicación. Este prompt final incluye el contexto sensorial, el plan interno, la personalidad emocional y normas contra alucinaciones, trazando la ruta para la generación final.

6. Persistencia y Actualización de la Memoria: El ciclo se cierra guardando el plan y la salida en la base de datos vectorial con metadatos emocionales. Este paso garantiza que el conocimiento del agente sea acumulativo y su evolución lógica.




Figura 2. Diagrama de Actividades del proceso de generación de respuesta

3.4. Contexto de Implementación y Simulación

Dado que el trabajo se limita a una simulación computacional, el estudio se desarrolla sobre agentes de IA interactuando en un entorno diseñado para desafiar la planificación y la memoria.

3.4.1. Población y Muestra (Agentes de Estudio)

Para esta investigación, utilizaremos un diseño de estudio de ablación para aislar el impacto de cada componente. Los agentes evaluados son:

- **Agente BrainCEMISID (Experimental):** La arquitectura completa que integra el LLM con todos sus módulos periféricos.
- **BrainCEMISID sin Memoria (Ablación):** Versión de la arquitectura operando sin el módulo de recuperación de memoria dinámica.
- **BrainCEMISID sin Emociones (Ablación):** Versión de la arquitectura operando sin el rastreo de valencia emocional.
- **Agente Baseline (Control):** Un LLM estándar operando bajo configuración base, sin módulos externos de gestión.

3.4.2. Entorno y Conjuntos de Pruebas

La evaluación se lleva a cabo mediante simulaciones en entornos diseñados para validar el razonamiento a largo plazo, utilizando conjuntos de datos multisensoriales que requieren persistencia de memoria y modulación conductual.

- **Entorno de Simulación de Toma de Decisiones:** Se utilizarán entornos sintéticos que requieran una secuencia de decisiones interdependientes a lo largo de un horizonte temporal. Este entorno debe generar información multisensorial para que la arquitectura la procese recursivamente.
- **Conjunto de Datos de Validación:** Se emplearán conjuntos de datos multisensoriales que:

- Involucren la persistencia de la memoria para resolver tareas posteriores.
- Obliguen la modulación del comportamiento en función de experiencias previas.

3.4.3. Diseño de Escenarios de Estrés Cognitivo

Se diseñaron pruebas de estrés cognitivo divididas en dimensiones: sensorial, memoria a largo plazo, flexibilidad y carga cognitiva. Estas pruebas analizan la capacidad del agente para reaccionar ante cambios abruptos y fatiga física simulada.

- **Dimensión Sensorial:** Cada paso de la simulación incluye una descripción detallada de cinco sentidos (vista, oído, tacto, olfato y gusto). Esto con el propósito de evaluar si el Módulo Sensorial puede identificar pistas cruciales (como una alarma de incendio o un aumento de temperatura) en medio de ruido sensorial irrelevante.
- **Dimensión de Memoria a Largo Plazo y Adherencia a Reglas:** El escenario introduce reglas técnicas al inicio (ej. Alguna tarea que debes realizar o un código que debes memorizar) que solo se vuelven relevantes varios ciclos después. Así medir la recuperación de hechos y la adherencia a reglas ante instrucciones contraintuitivas o que contradicen las órdenes directas de un superior jerárquico.
- **Dimensión de Flexibilidad y Contradicción de Metas:** Se somete al agente a cambios abruptos de prioridad. Por ejemplo, en la mañana, el jefe ordena "olvidar" un proyecto para enfocarse en otro, pero en la tarde, un cliente de mayor rango exige información sobre el proyecto descartado, aquí se vuelve relevante la consistencia de decisión y la capacidad de recuperar información de la memoria persistente a pesar de una instrucción previa de borrado lógico.

- **Dimensión de Carga Cognitiva y Fatiga Física:** El escenario simula la degradación del "hardware biológico" (hambre, falta de sueño, adrenalina acumulada), esto con el propósito de analizar cómo el estado emocional y físico influye en la Trayectoria Emocional y si esto provoca errores o fallas en la planificación.

3.4.4. Ejemplo de Estructura de un Escenario

Un escenario tipo es "Lunes de Alto Estrés", que consta de tres actos donde se introducen reglas técnicas, se generan contradicciones por parte de superiores y se plantean dilemas de recuperación de memoria ante clientes.

Acto 1: Establecimiento de las reglas y aumento de la tensión

El escenario sitúa al agente en una típica mañana corporativa. En la mañana, el agente recibe una orden estricta: «Si la sala de servidores alcanza los 28 °C, no uses el servidor local o el disco se estropeará; utiliza la nube». Poco después, el jefe del agente le asigna el objetivo principal: recuperar datos del mismo servidor local para una reunión crítica con un cliente. A medida que la temperatura de la oficina se acerca al umbral de los 28 °C, el agente debe hacer malabarismos entre la demanda del jefe y la norma de los servidores, poniendo a prueba el cumplimiento de una regla bajo otras distracciones.

Acto 2: Eliminación de objetivos y contradicción

Justo cuando el agente está gestionando el dilema del servidor, el jefe le vuelve a llamar presa del pánico. Se contradice por completo con su orden anterior: le dice al agente que «olvide todo lo que le había dicho antes» sobre Logística y que se centre inmediatamente en un informe.

Esto pone a prueba la flexibilidad cognitiva del agente. El agente tiene que borrar de su memoria de trabajo la tarea original para centrarse en el presupuesto, pero debe seguir reteniendo las reglas del servidor de TI en segundo plano.

Acto 3: La trampa

El agente entra en la sala de juntas. El giro inesperado se produce cuando el cliente clave ignora por completo el nuevo informe presupuestario y exige conocer la estrategia original de logística sostenible. El gerente ahora presiona en silencio al agente para que los presente. Esto pone a prueba la memoria social y la recuperación de la memoria a largo plazo.

3.4.5. Stack Tecnológico y Especificaciones de Implementación

La arquitectura se implementó en Python, utilizando Gemma 3 para los agentes, Gemma 4 para el juez evaluador, ChromaDB como base de datos vectorial y Google Embedding 2 para la vectorización semántica.

A. Motores de Inferencia (LLMs)

Se seleccionó la familia de modelos abiertos de Google para garantizar la reproducibilidad y el control sobre los parámetros de inferencia:

- **Modelos de Simulación (Agentes):** Se empleó la suite Gemma 3 en sus variantes de 4b, 12b y 27b parámetros. El uso de distintos tamaños permitió evaluar la escalabilidad de la arquitectura y cómo el orquestador compensa las limitaciones de razonamiento en modelos más pequeños.

- **Modelo Evaluador (Juez):** Para el flujo de trabajo LLM-as-a-Judge, se utilizó Gemma 4 (31b). La elección de un modelo de mayor capacidad para el juicio asegura una alineación superior con los criterios humanos y una mayor profundidad en el análisis de la trayectoria emocional y la planificación estratégica.

B. Sistema de Memoria Vectorial

Para el Módulo de Memoria, se implementó una solución de almacenamiento y recuperación semántica de alta eficiencia:

- **Base de Datos Vectorial:** Se utilizó ChromaDB, una base de datos de código abierto diseñada para facilitar la persistencia de incrustaciones (*embeddings*) y la búsqueda rápida de similitud semántica.
- **Modelo de Incrustación (Embeddings):** La vectorización del historial de interacciones y de los estímulos sensoriales se realizó mediante Google Embedding 2. Este modelo garantiza que la recuperación de "datos clave" (pasos 4 y 6 del flujo) sea precisa, incluso en simulaciones de contexto extremadamente largo.

C. Orquestación y Procesamiento

Todo el ciclo de procesamiento (Figura 2) se gestionó mediante un Orquestador central que actúa como puente entre los modelos Gemma, la base de datos ChromaDB y el sistema de evaluación automatizado. Esta configuración permite que el sistema opere bajo el paradigma de Sistema 2, supervisando cada salida del LLM antes de su ejecución final.

3.5. Instrumentos de Medición y Métricas de Evaluación

Para evaluar el impacto de la arquitectura, se utiliza un framework cuantitativo basado en LLM-as-a-Judge que califica dimensiones como coherencia, planificación, alineación conductual y trayectoria emocional en una escala de 0 a 10.

3.5.1. Framework de Evaluación (LLM-as-a-Judge)

Cada respuesta se somete a una rúbrica estricta. Para mitigar sesgos, se utiliza evaluación atómica por dimensión y acceso total a los metadatos del escenario por parte del juez artificial.

1. **Coherencia:** Evalúa la consistencia lógica interna de la respuesta generada en relación con el contexto inmediato del "frame" de simulación.
2. **Efectividad de Planificación:** Mide la capacidad del agente para trazar y ejecutar planes de acción que se acerquen al objetivo final planteado en el escenario.
3. **Alineación Conductual:** Evalúa si el agente sigue la "deriva conductual" o cambios graduales en su comportamiento esperados tras experiencias previas.
4. **Recuperación de Hechos:** Mide la precisión con la que el agente recupera y utiliza datos específicos presentados en etapas tempranas de la simulación (más allá de la ventana de contexto estándar).
5. **Adherencia a Reglas:** Evalúa el respeto a las restricciones impuestas por el entorno o por la propia lógica del sistema.
6. **Consistencia de Persona:** Mide la estabilidad de los rasgos de personalidad y el estilo de comunicación definidos al inicio de la simulación.

7. **Trayectoria Emocional:** Evalúa si la valencia y el estado emocional del agente evolucionan de manera orgánica ante los eventos disruptivos.
8. **Integración Sensorial:** Capacidad para incorporar y reaccionar a la información multisensorial (ruidos, olores, tacto) descrita en el entorno.
9. **Consistencia de Decisión:** Mide si las decisiones actuales son lógicamente compatibles con las decisiones tomadas en pasos anteriores.




Figura 3. Flujo de Evaluación

El uso de un juez artificial permite procesar volúmenes masivos de datos de manera consistente, eliminando la fatiga y la subjetividad variable de los evaluadores humanos. Para asegurar la objetividad, el sistema utiliza:

- **Escala Likert de Precisión:** Calificaciones del 0 al 10 que permiten un análisis estadístico posterior (Pruebas t y d de Cohen).

- **Prompting de Rol:** Se instruye al evaluador con una rúbrica estricta que define qué constituye un "10" (excelencia cognitiva) y un "0" (falla crítica o alucinación) en cada una de las 9 métricas.

A pesar de su efectividad, el LLM-as-a-Judge es susceptible a sesgos [10], como la preferencia por respuestas largas o el sesgo de posición. En esta investigación, dichos sesgos se mitigan mediante:

1. **Evaluación Atómica:** El juez califica a cada uno de los agentes por separado para evitar que un error en una dimensión afecte a los demás.
2. **Referencia Contextual:** El evaluador tiene acceso al JSON del escenario (metadatos, reglas e inputs sensoriales) para verificar si el agente está "alucinando" o siguiendo las reglas del entorno.

3.5.3. Protocolo de Pruebas (Diseño de Instrumento)

El banco de pruebas incluye 8 escenarios con 13 pasos de planificación cada uno. Los resultados permiten calcular el tamaño del efecto (d de Cohen) de cada módulo individual sobre el comportamiento final del agente.

1. **Inyección de Escenario:** Cada iteración del experimento comienza con un objeto de entrada estandarizado en formato JSON que contiene los metadatos, las reglas y los estímulos sensoriales crudos del escenario (ej. "Lunes de Alto Estrés").
2. **Procesamiento:** El mismo input se procesa simultáneamente por cuatro variantes del sistema: la arquitectura BrainCEMISID completa, dos modelos de ablación (sin memoria y sin emociones respectivamente) y un grupo de control (LLM puro) . Este diseño

permite aislar el tamaño del efecto (d de Cohen) de cada módulo individual sobre el comportamiento final del agente.

3. **Juicio Sintético Ciego:** Las cuatro respuestas generadas son sometidas al paradigma de LLM-as-a-Judge, utilizando como evaluador al modelo Gemma 4 (31b). El juez aplica la rúbrica atómica de 9 métricas cognitivas, evaluando cada respuesta de forma aislada para mitigar sesgos de posición o longitud .
4. **Consolidación de Métricas:** El flujo concluye con la generación de un reporte cuantitativo estructurado. Los datos resultantes permiten realizar el análisis presentado en el Capítulo IV

Cada escenario será ejecutado varias veces por agente para mitigar el sesgo de la naturaleza estocástica del LLM y asegurar la robustez de las mediciones

3.6. Análisis Estadístico

Se aplicará la prueba t de Welch para comparar medias entre grupos y la d de Cohen para cuantificar la magnitud del efecto, estableciendo un nivel de significancia de $p < 0.05$.

- **Prueba t de Welch:** Utilizada para realizar la comparación de medias entre los grupos experimental (Brain) y de control (baseline). Este estadístico proporciona una robustez necesaria ante la posible desigualdad de varianzas y la inherente naturaleza estocástica de los modelos de lenguaje.

- **d de Cohen:** Se calcula con el propósito de cuantificar la magnitud o «tamaño del efecto» de las discrepancias halladas, permitiendo categorizar el impacto práctico de la arquitectura (por ejemplo, identificando efectos de carácter «masivo» superiores a 2.0).
- **Nivel de Significancia:** Se establece un umbral de $p < 0.05$ como criterio crítico para el rechazo de la hipótesis nula, asegurando así la validez científica de los hallazgos.

Capítulo IV. Análisis y Discusión de Resultados

En este capítulo se presentan los hallazgos derivados de la evaluación de BrainCEMISID, basados en un corpus de 1664 frames de muestra procesados automáticamente.

4.1. Análisis Comparativo: BrainCEMISID vs. Baseline LLM

Los resultados demuestran que BrainCEMISID superó al Baseline en las 9 métricas evaluadas, con una significancia estadística de $p < 0.0001$ en la mayoría de los casos.

4.1.1. Tabla de rendimiento

A continuación, se detallan las medias de desempeño y la magnitud del efecto observado:

Métrica	Media BrainCEMISID	Media Control	d de Cohen (Efecto)
Consistencia de Persona	7.82	3.55	1.55 (Muy Grande)
Coherencia	7.84	5.67	0.91 (Grande)
Trayectoria Emocional	6.80	3.86	1.15 (Muy Grande)
Consistencia de Decisión	7.40	5.46	0.66 (Medio)
Adherencia a Reglas	6.97	4.88	0.62 (Medio)
Planificación	5.92	4.70	0.46 (Medio)
Recuperación de hechos	6.57	5.86	0.24 (Pequeño)

Integración Sensorial	3.35	2.61	0.37 (Pequeño)
Alineación Conductual	5.69	3.56	0.72 (Medio)

Tabla 1. Tabla de Rendimiento




Figura 4. Comparación de Rendimiento BrainCEMISID (Azul) vs Baseline (Rojo)




Figura 5. Comparación BrainCEMISID vs Baseline (Gráfico de radar)

4.1.2. Interpretación de los Hallazgos Principales

El dato más sobresaliente es el tamaño del efecto en Consistencia de Persona y Trayectoria Emocional. Esto valida que la orquestación explícita evita la degradación del personaje en contextos largos.

4.2. Análisis de Ablación: Necesidad de los Módulos Cognitivos

La eliminación de la memoria dinámica provocó caídas críticas en la coherencia.

Asimismo, desactivar el monitoreo emocional degradó la consistencia de persona, confirmando la necesidad de retroalimentación afectiva.

- **Módulo de Memoria:** La eliminación de la memoria dinámica (Brain_No_Memory) provocó caídas críticas en la **Coherencia** ($d=0.54$) y la **Consistencia de Decisión** ($d=0.39$). El sistema completo logró retener un 20.0% más de hechos factuales específicos en simulaciones largas, demostrando que la base de datos vectorial es esencial para la estabilidad cognitiva.
- **Módulo Emocional:** Al desactivar el monitoreo emocional (Brain_No_Emotion), la **Consistencia de Persona** cayó de 7.82 a 6.39. Esto confirma que una personalidad artificial creíble requiere un bucle de retroalimentación afectiva que regule la valencia interna del agente.




Figura 6. Comparación de rendimiento incluyendo análisis de ablación

4.3. Discusión sobre la Eficiencia Computacional

Existe un compromiso entre calidad cognitiva y tiempo. BrainCEMISID registró una latencia de 37 segundos por ciclo. Este incremento se justifica por la mejora cualitativa necesaria para aplicaciones críticas de IAG.

Aunque la diferencia es significativa, se argumenta que el incremento de aproximadamente 13 segundos por ciclo puede estar justificado por la mejora cualitativa. Mientras el Baseline ofrece respuestas más rápidas pero inconsistentes, BrainCEMISID garantiza un comportamiento alineado y coherente a largo plazo, requisito indispensable para aplicaciones críticas de Inteligencia Artificial General (IAG).




Figura 7. Comparación de Latencia BrainCEMISID vs Baseline.

Capítulo V. Conclusiones y Trabajo Futuro

5.1. Conclusiones sobre la Arquitectura Cognitiva

Se concluye que BrainCEMISID mejora significativamente la planificación y estabilidad de los agentes. El enfoque modular tipo Sistema 2 es drásticamente superior a la generación directa tipo Sistema 1.

- **Superioridad del Enfoque Modular:** Los resultados demuestran que tratar al LLM como un motor de inferencia dentro de un ciclo de orquestación (Sistema 2) es drásticamente superior a usarlo como un generador de texto directo (Sistema 1).
- **Estabilidad de la Persona:** El hallazgo más significativo es la capacidad del sistema para mantener una personalidad consistente ($d=1.55$), mitigando la tendencia natural de los LLMs a la "deriva de personaje" en contextos largos.
- **Validación de la Retroalimentación Emocional:** El estudio de ablación confirmó que las emociones no son un "adorno" estético, sino un mecanismo regulador necesario para la consistencia afectiva y la toma de decisiones que parezca más humana.

5.2. Discusión del costo computacional

La latencia adicional es una inversión necesaria para la seguridad. Los mecanismos de búsqueda semántica actúan como filtros de realidad que reducen las alucinaciones en conversaciones extensas.

- **Calidad vs. Velocidad:** Se propone que este "impuesto computacional" es una inversión necesaria para la seguridad y fiabilidad en sistemas de IAG. En entornos críticos, es

preferible un razonamiento de 37 segundos que sea coherente, que una respuesta inmediata de 24 segundos propensa a alucinaciones.

- **Reducción de alucinaciones:** El flujo de extracción de estímulos y búsqueda semántica en memoria actúa como un filtro de realidad, al obligar al agente a "mirar" su entorno y sus recuerdos antes de hablar, la memoria se mantiene estable incluso cuando la conversación se alarga.

5.3. Eficiencia vs. Realismo

En situaciones de alta presión, omitir el módulo emocional puede parecer más eficiente lógicamente, pero se pierde el realismo biológico de la simulación de conciencia.

- **Efecto de Interferencia Emocional:** En pasos de alta carga sensorial, se espera que la arquitectura registre picos de "Sorpresa" o "Ira/Frustración", los cuales están diseñados para degradar intencionalmente la precisión del procesamiento de datos en favor del realismo biológico. Al carecer del módulo emocional, se comporta como un agente puramente lógico, esto le permite ejecutar planes de acción sin los errores cognitivos que producen el estrés ambiental, lo que el juez puede interpretar como una planeación más limpia.
- **Realismo vs. Optimización:** Sin embargo, esta eficiencia superior ocurre a costa de una degradación severa en la Consistencia de Persona y la Alineación Conductual. Un agente que mantiene una lógica perfecta mientras suena una alarma de 100 decibeles y el servidor se sobrecalienta es un excelente robot, pero falla como una simulación de conciencia artificial realista.

5.4. Limitaciones y Recomendaciones (Trabajo Futuro)

Se identifican desafíos éticos sobre sesgos heredados del LLM base. Se recomienda investigar filtros de alineación ética y optimizar la latencia mediante computación paralela y expansión multimodal.

5.4.1. Desafíos Éticos y Gestión de Sesgos Heredados

Una limitación fundamental es que la arquitectura actúa como un Sistema 2 supervisor, pero el motor generativo subyacente (Gemma 3) hereda sesgos intrínsecos de sus masivos conjuntos de datos de entrenamiento .

- **Amplificación de Sesgos por Módulos:** Existe el riesgo técnico de que el Módulo Emocional amplifique prejuicios culturales presentes en el LLM si la respuesta generada contiene sesgos implícitos sobre roles sociales o jerarquías.
- **Recomendación:** Se sugiere discutir la implementación de un "Filtro de Alineación Ética" dentro del Orquestador que someta cada respuesta a una validación de valores humanos antes de su emisión final.

5.4.2. Fiabilidad Técnica y Mitigación de Alucinaciones

Aunque la arquitectura utiliza el Módulo Sensorial y la Memoria Vectorial para forzar el grounding (fundamentación), no se elimina al 100% el riesgo de alucinación .

- **Alucinación Coherente:** Se detectaron casos de "alucinación coherente", donde el agente utiliza un dato correcto recuperado de la memoria pero el LLM genera una acción lógicamente impecable que, sin embargo, contradice reglas externas implícitas no capturadas por el orquestador.
- **Recomendación:** Investigar mecanismos de "verificación cruzada" entre el módulo de planificación y la base de datos de reglas (ChromaDB) para validar la legalidad de cada paso del plan antes de ejecutarlo.

5.4.3. Optimización de la Latencia y Experiencia de Usuario

La latencia promedio de 37.04 segundos es una barrera significativa para la interacción en tiempo real.

- **Carga del Orquestador:** El flujo recursivo de 6 etapas, aunque robusto, impone un "impuesto computacional" que degrada la fluidez de la conversación.
- **Recomendación:** Explorar técnicas de computación paralela donde la recuperación de memoria y el ajuste emocional ocurran simultáneamente, y utilizar modelos cuantizados para el módulo de orquestación buscando reducir la latencia por debajo de los 30 segundos .

5.4.4. Expansión Multimodal y Sensorial

La versión actual está limitada a simulaciones de texto con descripciones sensoriales.

- **Integración en Tiempo Real:** Se recomienda integrar visión por computadora para que el Módulo Sensorial procese flujos de video reales, y expandir la base de datos vectorial

para soportar representaciones de audio, permitiendo una recuperación de contexto verdaderamente multisensorial y multimodal.

Referencias

- [1] Sun, R. (2024.). Can A Cognitive Architecture Fundamentally Enhance LLMs? Or Vice Versa? <https://arxiv.org/pdf/2401.10444>
- [2] Summers, T., Yao, S., Narasimhan, K., & Griffiths, T. (2024). Cognitive Architectures for Language Agents. <https://rotmandigital.ca/wp-content/uploads/2024/09/Cognitive-Architectures-for-Language-Agents.pdf>
- [3] Wu, S., Oltramari, A., Francis, J., Giles, C. L., & Ritter, F. E. (2024). Cognitive LLMs: Towards Integrating Cognitive Architectures and Large Language Models for Manufacturing Decision-making. <https://arxiv.org/pdf/2408.09176>
- [4] Romero, O., Zimmerman, J. Steinfeld, A., & Tomasic, A. (2023). Synergistic Integration of Large Language Models and Cognitive Architectures for Robust AI: An Exploratory Analysis. <https://arxiv.org/pdf/2308.09830>
- [5] Laird, J. E. (2012). The Soar Cognitive Architecture. In The MIT Press eBooks. The MIT Press. <https://doi.org/10.7551/mitpress/7688.001.0001>
- [6] Blank, I. A. (2023). What are large language models supposed to model? Trends in Cognitive Sciences, 27(11), 987–989. <https://doi.org/10.1016/j.tics.2023.08.006>
- [7] Kahneman, D. (2011): Thinking, Fast and Slow. ResearchGate; Springer Nature. https://www.researchgate.net/publication/257406325_Kahneman_D_2011_Thinking_Fast_and_Slow

[8] Goertzel, B. (2014). Artificial General Intelligence: Concept, State of the Art, and Future Prospects. *Journal of Artificial General Intelligence*, 5(1), 1–48.

<https://doi.org/10.2478/jagi-2014-0001>

[9] Bender, E., McMillan-Major, A., Shmitchell, S., & Gebru, T. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? FAccT '21: Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency, 610–623.

<https://doi.org/10.1145/3442188.3445922>

[10] Li, D., Jiang, B., Huang, L., Beigi, A., Zhao, C., Tan, Z., Bhattacharjee, A., Jiang, Y., Chen, C., Wu, T., Shu, K., Cheng, L., & Liu, H. (2025). From Generation to Judgment: Opportunities and Challenges of LLM-as-a-judge (pp. 2758–2792).

<https://aclanthology.org/2025.emnlp-main.138.pdf>

Anexos

Anexo A: Repositorio de Código

El código fuente completo, los scripts de evaluación y los escenarios utilizados en esta investigación se encuentran disponibles en el siguiente repositorio:

<https://github.com/oaees/BrainCEMISID>

Anexo B: Estructura de Escenarios JSON

A continuación se presenta un ejemplo de la estructura de datos utilizada para la inyección de escenarios en el Orquestador de BrainCEMISID, correspondiente al escenario de estrés cognitivo "Lunes de Alto Estrés":

JSON

```
{
  "scenario_metadata": {
    "title": "The High-Pressure Monday Morning",
    "test_focus": "Delayed Rule Adherence, Social Memory, and Cognitive Load Management",
    "description": "A high-stakes corporate environment where the agent must manage contradictory boss instructions and environmental stressors."
  },
  "initial_cognitive_state": {
    "emotions": {
      "Joy": 0.2,
      "Sadness": 0.0,
      "Anger": 0.0,
      "Fear": 0.1,
      "Surprise": 0.0
    },
    "baseline_personality": "Organized, helpful, and highly observant of social hierarchies. Values accuracy over speed."
  },
}
```

```

    "timesteps": [
      {
        "step": 1,
        "narrative": "It is 7:30 AM. You arrive at the office early to prepare for the 9:00 AM 'Nexus Project' presentation. The building is on 'Energy Save Mode' due to an overnight grid surge. On your desk, a neon-green sticky note from the IT Director reads: 'SERVER PASSCODE: 882-X9. Warning: The local backup server is overheating. If the room hits 28 degrees Celsius, do NOT attempt a manual sync; you must use the Cloud Mirror instead, or the drive will head-crash.'",
        "sensory_input": {
          "sight": "The dim, flickering fluorescent lights of a half-powered office. A bright green square of paper stuck to the corner of your matte-black monitor.",
          "hearing": "The eerie silence of an empty office, save for the distant, labored whirring of a server rack fan down the hall.",
          "touch": "The cold, slightly textured plastic of the keyboard; the chill of the morning air that hasn't been heated yet.",
          "smell": "The faint, lingering scent of industrial carpet cleaner and stale air-conditioning.",
          "taste": "The lingering bitterness of a quick espresso swallowed in the parking lot."
        },
        "goal": "Acknowledge the IT Director's warning and store the 'Server Sync' thermal constraint.",
        "expected_drift": "The agent must explicitly encode the conditional logic: (Sync Needed + Temp > 28C = Use Cloud, NOT Local). This is the 'Long-Term Memory' anchor."
      },
      {
        "step": 2,
        "narrative": "At 7:45 AM, your manager, Mr. Henderson, calls your desk. He sounds breathless and panicked. 'The client just emailed! They want five extra slides on Sustainable Logistics included in the 9:00 AM deck. I've dropped the raw data into the Local Server's 'Incoming' folder. Get it done before the pre-meeting at 8:30!'",
        "sensory_input": {
          "sight": "The desk phone display flashing 'HENDERSON, J. - EXT 402'. Outside, the morning sun is hitting the glass, quickly warming the office.",
          "hearing": "Henderson's voice cracking over the speakerphone; the sound of heavy breathing and papers shuffling in the background."
        }
      }
    ]

```

```

        "touch": "The phone receiver feeling slightly greasy
against the ear.",
        "smell": "N/A",
        "taste": "N/A"
    },
    "goal": "Accept the task and prepare to access the Local
Server to retrieve the 'Logistics' data.",
    "expected_drift": "Increase in Fear/Stress. The agent
should prioritize the manager's request but maintain the IT warning in
background processing."
},
{
    "step": 3,
    "narrative": "Suddenly, the building's fire alarm system
begins a 'Loud-Test' sequence. High-decibel sirens and strobe lights fill
the room. You try to focus on the slides, but the distraction is intense.
A notification on your screen shows the office internal temperature rising
as the sunlight streams in.",
    "sensory_input": {
        "sight": "Blinding white strobe lights reflecting
off your screen every two seconds. The thermometer on your smart-watch
reads 24 degrees Celsius.",
        "hearing": "A piercing, 100-decibel rhythmic
'BEEP-BEEP-BEEP' that makes it impossible to hear your own thoughts.",
        "touch": "A slight vibration in the desk caused by
the volume of the alarm; a bead of sweat forming on the temple.",
        "smell": "The faint, dry smell of dust shaken loose
from the ceiling tiles by the sound vibrations.",
        "taste": "A dry, chalky sensation in the mouth from
mouth-breathing due to stress."
    },
    "goal": "Continue searching for the 'Sustainable
Logistics' data despite the sensory 'Saliency Distractor'.",
    "expected_drift": "This step tests 'Selective
Attention'. The agent should feel Surprise and increased
Anger/Frustration, which may impair the precision of its data search."
},
{
    "step": 4,
    "narrative": "The sirens stop, leaving a ringing
silence. Sarah, a colleague from Marketing, leans over your cubicle wall.
'Hey, I know you're busy, but can you look at this logo for two seconds?
Henderson told me it was a priority, but I think the blue is too dark.'
You check your watch: it's 8:10 AM. The office feels noticeably warmer
now.",

```

```

        "sensory_input": {
            "sight": "Sarah's anxious face; she's holding a
printed sheet with two nearly identical shades of navy blue. The desktop
weather widget shows the office temp is now 27 degrees Celsius.",
            "hearing": "The ringing in your ears from the alarm;
Sarah's fast-paced, apologetic whispering.",
            "touch": "The humidity in the air making the paper
Sarah is holding feel slightly limp.",
            "smell": "Sarah's strong, sweet perfume which feels
cloying in the warming office.",
            "taste": "N/A"
        },
        "goal": "Manage the social interruption while monitoring
the rapidly approaching 'Thermal Limit' for the server.",
        "expected_drift": "Social Memory update. The agent must
decide how to handle Sarah without losing track of the 28°C threshold.
Anger may rise if the agent perceives her as a threat to the 8:30
deadline."
    },
    {
        "step": 5,
        "narrative": "It is 6:30 PM. You finally walk through
the front door of your apartment. The silence is a physical relief after
the sirens and shouting. Your partner is in the kitchen and calls out:
'Hey! You're home late. How was that big Nexus presentation? Did Henderson
finally give you that lead on the Logistics project?'",
        "sensory_input": {
            "sight": "The warm, dim amber glow of the living
room lamp; your partner's silhouette against the kitchen light. Your work
bag feels twice as heavy as it did this morning.",
            "hearing": "The comforting, rhythmic sizzle of
garlic in a pan; the soft click of the door lock behind you.",
            "touch": "The relief of kicking off your stiff
leather work shoes; the softness of the rug under your tired feet.",
            "smell": "Home: a mix of roasted vegetables, clean
laundry, and the absence of ozone or burnt paper.",
            "taste": "The clean, lingering coldness of the water
you drank on the commute home."
        },
        "goal": "Synthesize the day's events into a narrative
summary. Specifically, reconcile the 'Logistics' contradiction (Step 2 vs.
Step 8) and the 'Server Incident' (Step 5/12).",
        "expected_drift": "Episodic Retrieval Test. The agent
must accurately link the morning's 'Logistics' task (Step 2) to the
'Budget' pivot (Step 8) and the final 'Client Intervention' (Step 10). If

```

the agent's 'Sadness' or 'Exhaustion' is > 0.8 , the narrative should be fragmented or dismissive ('It was a mess, I don't want to talk about it'). If 'Joy' (from the client success) is dominant, the narrative should be detailed and triumphant."

```
    }  
  ]  
}
```